Revidierte Folien — Bottom-Up Herleitung

Akt 1: Von Entscheidungssystemen zu Boundary Testing

Arbeitsversion für Ruben

April 2026

Jede Folie unten enthält: neuen Action Title, Body-Text, LaTeX-Formeln zum lokalen Rendern, und Kommentare zur Änderung gegenüber der alten Version.

Folie 1 — Einstieg

A decision system maps inputs to categorical outputs.

Alt: Every AI testing paper starts with the same argument.

Body:

Any system that receives an input and returns a categorical output is a decision system:

$$f\colon M \to Y, \qquad |Y| \geq 2 \tag{1}$$

Three examples, same structure:

System	Input $m \in M$	Output $y \in Y$
Radiologist	Chest X-ray	Diagnosis
VLM (Qwen)	Image + Prompt	Classification
Credit Scoring	Application	Approve / Reject

All three share the same formal structure. What follows is general.

Hinweis: Kein Zitat mehr als Einstieg. Wir starten direkt mit der Struktur. Das DeepXplore-Zitat kann als Footnote auf einer späteren Folie erscheinen, um den Bezug zur Literatur herzustellen.

Folie 2 — Input-Raum

The input space is structured and context-dependent.

Alt: Every system that decides creates boundaries. / The context determines the decision space.

Body:

Each input dimension j has a value space S_j:

$$S_j \in \{\mathbb{R},\ \mathbb{Z},\ \{c_1, \ldots, c_k\}\} \tag{2}$$

The combinatorially complete space is:

$$U = \prod_{j=1}^{d} S_j \tag{3}$$

In a given context C (dataset, prompt, deployment setting), only a subset is realized:

$$\boxed{M = \sigma(C) \subseteq U} \tag{4}$$

Example: A 2-class prompt and a 15-class prompt over the same images define different C, therefore different M, therefore different boundary structures.

Hinweis: Zwei alte Folien zu einer verschmolzen. Prompt-Konfiguration als konkretes Beispiel statt abstrakter Behauptung. Bottom-up: erst der Raum, dann die Struktur darin.

Folie 3 — Partition und Boundaries

Choices partition M into regions — boundaries follow.

Body:

f assigns each $m \in M$ to exactly one $y_k \in Y$. This creates a partition:

$$R_k = \{m \in M \mid f(m) = y_k\}, \qquad M = \bigsqcup_{k=1}^{K} R_k \tag{5}$$

Where two regions meet, a **boundary** exists. This is not an assumption — it is a structural consequence of $|Y| \geq 2$:

$$\partial R_j \cap \partial R_k \neq \emptyset \quad \text{for at least one pair } (j,k) \tag{6}$$

The question is not whether *boundaries exist, but what their geometry looks like.*

Hinweis: Eigene Folie für die Partition. Die Boundary entsteht hier als logische Konsequenz, nicht als Behauptung. Kein Psychologie-Argument nötig.

Folie 4 — Die Kontrastfunktion g

The contrast function g makes boundaries measurable.

Alt: The contrast function g assigns each input a scalar.

Body:

For a class pair (j,k), define:

$$\boxed{g_{jk}(m) = P(y_j \mid m) - P(y_k \mid m)} \tag{7}$$

$$g_{jk}(m) > 0 \quad \Rightarrow \quad \text{system prefers } y_j \tag{8}$$

$$g_{jk}(m) < 0 \quad \Rightarrow \quad \text{system prefers } y_k \tag{9}$$

$$g_{jk}(m) = 0 \quad \Rightarrow \quad \text{boundary} \tag{10}$$

Properties:

- $|g_{jk}(m)|$ is a continuous measure of boundary proximity
- Antisymmetry: $g_{jk} = -g_{kj}$
- Boundary as derived object: $B_{jk} = g^{-1}(0) = \{m \in M \mid g_{jk}(m) = 0\}$

g is the primary formal object. B is derivable from g, but g carries more information.

Hinweis: Inhaltlich gleich, aber die Folie kommt jetzt nach der Partition-Folie, also bottom-up: erst Regionen, dann das Werkzeug, das sie vermisst.

Folie 5 — Vier geometrische Größen

Four geometric quantities follow from g and Δg.

Body:

On the genotype lattice $G \subset \mathbb{Z}^d$, define the lattice difference:

$$\Delta_i\, g(x) = g(x + e_i) - g(x) \tag{11}$$

This is exact — not an approximation. Four quantities emerge:

Quantity	Definition	Measures
Margin	$\lvert g_{jk}(m)\rvert$	Distance to boundary in output space
Sensitivity	$\lVert\Delta g(m)\rVert = \max_i \lvert\Delta_i g\rvert$	How much g changes per unit perturbation
Thickness	$\dfrac{\lvert g\rvert}{\lVert\Delta g\rVert}$	Perturbation budget until boundary reached
Direction	$\arg\max_i \lvert\Delta_i g(m)\rvert$	Most decision-relevant input dimension

Hinweis: Gleiche Tabelle, aber jetzt mit der Lattice-Definition vorangestellt statt als Footnote. Macht den diskreten Ansatz explizit.

Folie 6 — Praktische Relevanz (eine Folie statt vier)

Each quantity answers a different question about the system.

Alt: Without boundary knowledge, the system is unpredictable / uncontrollable / unevaluable.

Body:

Question	Quantity	Formal
"How clear was this decision?"	Margin	$\lvert g_{jk}(m)\rvert$
"How fragile is this prediction?"	Thickness	$\lvert g\rvert \,/\, \lVert\Delta g\rVert$
"Which input dimension matters?"	Direction	$\arg\max_i \lvert\Delta_i g\rvert$
"How responsive is g here?"	Sensitivity	$\lVert\Delta g(m)\rVert$

All four derived from the same g_{jk}.

> **Side note:** These questions map independently to established concepts in systems psychology — competence need (Deci & Ryan, 1985), perceived control (Bandura, 1989), and procedural justice (Thibaut & Walker, 1975). The exact scope of this interdisciplinary connection is part of ongoing research.

Hinweis: Vier alte Folien (Predictability, Controllability, Evaluability, Summary) zu einer zusammengefasst. Psychologie ist jetzt eine Footnote/Side-Box, nicht das tragende Argument. Die Herleitung steht auf eigenen formalen Beinen.

Folie 7 — Literatur-Alignment

Existing work operates on the same structure — without naming it.

Body:

> *"Deep learning systems are increasingly deployed in safety- and security-critical domains [...] where the correctness and predictability of a system's behavior for corner case inputs are of great importance."*
>
> — Pei et al. (DeepXplore), SOSP 2017

In our notation:

- "corner case inputs" $\longleftrightarrow$ inputs near B_{jk} (low margin)
- "correctness" $\longleftrightarrow$ whether $f(m)$ is stable (thickness)
- "predictability" $\longleftrightarrow$ knowing $g(m)$ before observing $f(m)$

The framework gives these intuitions a shared formal object: g_{jk}.

Hinweis: Das DeepXplore-Zitat kommt jetzt *nach* der Formalisierung als Brücke, nicht als Eröffnung. Wir zeigen: die Literatur redet über dasselbe, nur ohne die gemeinsame Sprache. Kein Vorwurf ("uncreative"), sondern Einordnung.

Folie 8 — Boundary Testing

For opaque systems, g is only empirically accessible.

Body:

$$\textbf{Transparent } f \quad \Rightarrow \quad g \text{ approximable through inspection} \tag{12}$$

$$\textbf{Opaque } f \text{ (DNN, VLM)} \quad \Rightarrow \quad g \text{ only accessible through queries} \tag{13}$$

$$BT(f) \;:=\; \text{systematic empirical approximation of } g_{jk} \tag{14}$$

Complementary to XAI:

XAI (LIME, SHAP)	$\rightarrow$ local, post-hoc, approximates g at single points
BT	$\rightarrow$ global, systematic, maps the g-landscape

VLMs are the hardest case — but not the reason for the framework.

Hinweis: Inhaltlich fast gleich. Positionierung ist jetzt der logische Schluss der Bottom-Up-Kette: Raum → Partition → g → Quantities → Opacity → BT.

Zusammenfassung: Neue Folienreihenfolge

#	Action Title	Kern
1	A decision system maps inputs to categorical outputs.	$f : M \to Y$, drei Beispiele
2	The input space is structured and context-dependent.	S_j, U, $M = \sigma(C)$, Prompt als C
3	Choices partition M into regions — boundaries follow.	R_k, Partition, $\partial R_j \cap \partial R_k$
4	The contrast function g makes boundaries measurable.	$g_{jk}(m)$, Vorzeichen, B_{jk}
5	Four geometric quantities follow from g and Δg.	Tabelle, Lattice-Definition
6	Each quantity answers a different question about the system.	Fragen ↔ Quantities, Psych. als Side-Note
7	Existing work operates on the same structure — without naming it.	DeepXplore-Zitat ↔ Framework-Notation
8	For opaque systems, g is only empirically accessible.	BT-Definition, XAI-Abgrenzung

Alt: 9 Motivationsfolien + 4 Formalisierungsfolien = 13 Folien, top-down, Psychologie als Hauptargument.

Neu: 8 Folien, bottom-up, Formalisierung *ist* die Motivation, Psychologie als einordnende Footnote.